

Môn học IS603, năm 2026

Hệ thống truy hồi công thức nấu ăn

Nhóm 1, Bài tập A1

GIẢNG VIÊN HƯỚNG DẪN

TS. Phạm Đỗ Kim Chi

THÀNH VIÊN NHÓM

Châu Ngọc Hoa Thy
Triệu Thị Thùy Dung

Lê Thành Duy Ân
Trịnh Huỳnh Đăng

Bài trình bày gồm hai phần: xây dựng và đánh giá

Mở đầu: vấn đề và mục tiêu

Cuối bài: kết luận và hướng phát triển

PHẦN 1

Xây dựng hệ thống

Dữ liệu công thức

Thiết kế cơ sở dữ liệu

Cách chia đoạn văn bản

Các mô hình sử dụng

Chọn mô hình xếp hạng lại

Luồng xử lý một truy vấn

PHẦN 2

Đánh giá hệ thống

Bộ dữ liệu đánh giá

So sánh bốn cấu hình

Ảnh hưởng của việc trùng từ

Phân tích lỗi

Hạn chế của nghiên cứu

Người dùng nhớ món ăn qua mô tả, không nhớ tên món

Nếu chỉ tìm theo từ khóa, hệ thống sẽ bỏ sót công thức đúng khi người dùng dùng từ khác với công thức.

1

Tìm kết hợp

Hệ thống tìm cả theo từ khóa (BM25) và theo vector, chạy trên PostgreSQL và ParadeDB.

2

So sánh công bằng

Bốn cách tìm được chạy trên cùng dữ liệu và cùng số đoạn đầu vào.

3

Hai tầng

Tầng 1 lấy nhiều kết quả để không bỏ sót. Tầng 2 sắp xếp lại để đưa kết quả đúng lên đầu.

4

Đo bằng chỉ số chuẩn

Nhóm dùng Recall@k, MRR và nDCG@k trên một bộ truy vấn được kiểm tra riêng.

Phần 1

Xây dựng hệ thống

Phần này trình bày dữ liệu, cách lưu trữ, cách chia đoạn, các mô hình, cách chọn mô hình xếp hạng lại và luồng xử lý một truy vấn.

Dữ liệu gồm 32,719 công thức từ Allrecipes

32,719

công thức

Bộ gốc có 32,722 dòng, nhóm bỏ 3 dòng trùng URL.

22

danh mục món ăn

Nhiều nhất là món khai vị, món tráng miệng và món phụ.

19 / 32

cột dinh dưỡng được giữ

13 cột bị bỏ vì trống ở hơn 99% số dòng.

Bốn trường dùng để tìm kiếm

title

description

ingredients

directions

Các trường dùng để lọc

category

rating

rating_count

prep_time

cook_time

total_time

servings

calories

protein


fat

carbohydrates


sodium

Cơ sở dữ liệu quan hệ gồm 7 bảng trên PostgreSQL

BẢNG NGUỒN, CHUẨN HÓA



BẢNG DÙNG ĐỂ TÌM KIẾM



Ba phân vùng theo strategy, kèm số đoạn

chunk_fixed	chunk_semantic	chunk_sentence
165,974	166,438	175,752

Vì sao bảng chunk chép lại các cột lọc? ParadeDB chỉ lọc được trên cột của chính bảng có chỉ mục. Khi cột lọc nằm sẵn trong bảng chunk, việc tìm theo từ khóa, theo vector và lọc đều chạy trong một chỉ mục.

Ba cách chia phần hướng dẫn nấu, cho số đoạn gần bằng nhau

Mỗi công thức có một đoạn tóm tắt, một đoạn nguyên liệu và nhiều đoạn hướng dẫn. Chỉ các đoạn hướng dẫn thay đổi giữa ba cách chia, nên tổng số đoạn bằng số đoạn hướng dẫn cộng 65,438.

CÁCH CHIA	CÁCH CẮT PHẦN HƯỚNG DẪN	ĐOẠN HƯỚNG DẪN	TỔNG SỐ ĐOẠN	ĐỘ DÀI TRUNG VỊ
Fixed	Cắt sau mỗi 56 token, tại ranh giới từ	100,536	165,974	224 ký tự
Semantic	Cắt ở chỗ hai câu liền nhau ít giống nhau nhất, mỗi đoạn dài 80 đến 400 ký tự	101,000	166,438	185 ký tự
Sentence	Gộp 3 câu liên tiếp thành một đoạn	110,314	175,752	178 ký tự

Tham số được chỉnh để ba cách chia cho số đoạn hướng dẫn tương đương. Vì vậy khác biệt về kết quả đến từ vị trí cắt, không phải từ số lượng đoạn.

Hệ thống dùng bốn mô hình có sẵn, mỗi mô hình làm một việc

TẠO VECTOR

`nomic-embed-text`

Biến đoạn văn và truy vấn thành vector 768 chiều. Dense xếp hạng theo độ tương đồng cosine.

XẾP HẠNG LẠI

`mxbai-rerank-base-v1`

Đọc truy vấn và từng đoạn cùng lúc rồi chấm điểm lại 50 đoạn đầu trong Hybrid. Cách nhóm chọn mô hình này ở trang sau.

ĐẾM TOKEN

`bert-base-uncased`

Dùng để đếm token khi chia đoạn theo cách fixed.

VIẾT TRUY VẤN THỬ

`qwen2.5:7b`


Viết truy vấn đánh giá dài 3 đến 8 từ và không dùng tên món.

Nhóm chọn mxbai-rerank-base vì có MRR cao nhất mà chỉ chậm hơn bge-reranker-base 25%

Nhóm thử bốn cross-encoder, lần lượt thay vào bước xếp hạng lại của Hybrid. Mỗi mô hình chạy trên cùng 298 truy vấn của bộ đánh giá ở phần 2, và nhóm so sánh hai tiêu chí: MRR và thời gian.



Một truy vấn mất khoảng 725 ms, trong đó 93% là bước xếp hạng lại



THỜI GIAN CỦA MỘT TRUY VẤN HYBRID, TRUNG VỊ 725 MS



$$\text{RRF}(d) = \sum_{r \in \{BM25, Dense\}} \frac{1}{k + \text{rank}_r(d)}$$

Trong đó $\text{rank}_r(d)$ là thứ hạng của đoạn d trong danh sách r , bắt đầu từ 1, và $k = 60$. Công thức chỉ dùng thứ hạng, nên không cần đưa điểm BM25 và điểm cosine về cùng một thang.


Phần 2

Đánh giá hệ thống

Phần này trình bày bộ dữ liệu đánh giá, kết quả của bốn cấu hình và các lỗi còn lại.

Bộ đánh giá có 298 truy vấn và 691 cặp được chấm là liên quan


BỘ DỮ LIỆU ĐÁNH GIÁ Tạo truy vấn, chọn cặp để chấm, rồi chấm nhãn.



BỐN CẤU HÌNH ĐƯỢC SO SÁNH Mỗi cấu hình lấy 50 đoạn đầu và được chấm trên 20 công thức đầu.



Hybrid có nDCG@10 cao nhất là 0.916, nhưng mỗi truy vấn mất khoảng 0.7 giây



Fusion cao hơn Dense 0.032 mà thời gian gần như không đổi.

Hybrid cao hơn Fusion thêm 0.140, nhưng chậm hơn rất nhiều vì bước xếp hạng lại.

Hybrid cao nhất ở mọi chỉ số, còn cách chia đoạn gần như không đổi kết quả

CÁCH CHIA	CẤU HÌNH	R@5	R@10	R@20	MRR	NDCG@5	NDCG@10
fixed	Sparse	0.836	0.909	0.933	0.689	0.717	0.741
	Dense	0.852	0.903	0.930	0.691	0.725	0.742
	Fusion	0.876	0.923	0.963	0.714	0.748	0.763
	Hybrid	0.970	0.977	0.980	0.894	0.913	0.915
semantic	Sparse	0.822	0.896	0.936	0.664	0.694	0.718
	Dense	0.859	0.896	0.943	0.697	0.732	0.744
	Fusion	0.879	0.940	0.960	0.725	0.756	0.776
	Hybrid	0.966	0.977	0.977	0.895	0.912	0.916
sentence	Sparse	0.822	0.889	0.936	0.668	0.697	0.719
	Dense	0.842	0.883	0.926	0.691	0.723	0.736
	Fusion	0.852	0.913	0.953	0.703	0.732	0.752
	Hybrid	0.966	0.977	0.980	0.888	0.907	0.910

Khi truy vấn ít trùng từ với công thức, BM25 giảm 0.221 còn Hybrid chỉ giảm 0.043

● Trùng từ nhiều, 154 truy vấn ○ Trùng từ ít, 144 truy vấn

Recall@5, cách chia semantic



Đây chính là vấn đề ở phần mở đầu: người dùng mô tả món ăn bằng từ khác với công thức. Hybrid gần như không bị ảnh hưởng.

Phần lớn lỗi nằm ở tầng lấy kết quả, không nằm ở bước xếp hạng lại

E1

TẦNG 1, BM25

Lệch từ vựng

16 đến 17 truy vấn

Truy vấn và công thức dùng từ khác nhau cho cùng một ý.

Truy vấn “*creamy black bean and tomato stew*” tìm món Black Bean and Tomato Soup. BM25 xếp hạng 20, Dense hạng 2, Hybrid hạng 1.

E2

TẦNG 1, DENSE

Mất chi tiết cụ thể

17 đến 19 truy vấn

Nguyên liệu hiếm, con số hoặc phủ định bị bỏ qua.

Truy vấn “*yellow split pea soup with curry powder*” tìm món Vegan Split Pea Soup II. BM25 xếp hạng 1, Dense ngoài top 20, Hybrid hạng 1.

E3

TẦNG 1

Không tìm thấy

6 đến 7 truy vấn

Không có công thức đúng nào trong 20 kết quả đầu của Hybrid.

Truy vấn “*citrusy alcoholic drink with cola*” tìm món Long Island Iced Tea. Cả bốn cấu hình đều không tìm thấy.

E4

TẦNG 2

Xếp hạng lại sai

0 đến 2 truy vấn

Công thức đúng nằm trong top 5 sau RRF nhưng bị đẩy ra ngoài.

Truy vấn “*warm, coffee-flavored dessert in mug*” tìm món Easy Coffee Mug Cake. Sau RRF hạng 1, sau xếp hạng lại hạng 7.

E6

BỘ ĐÁNH GIÁ

Lỗi nhãn hoặc truy vấn

55 truy vấn mơ hồ

Truy vấn quá mơ hồ hoặc nhãn bị chấm sai. Có thêm 30 nhãn chỉ đúng một phần.

Truy vấn “*creamy tomato based dressing with vinegar*” tìm món Dorothy Lynch Style Salad Dressing, nhưng công thức không nói món này có kem.

Bốn điều rút ra từ phân tích lỗi

1 **BM25 và Dense bù cho nhau**

E1 và E2 là hai nhóm lỗi lớn nhất, khoảng 17 truy vấn mỗi cách chia. Hybrid sửa được phần lớn các trường hợp này.

2 **Cách chia đoạn không phải nguồn lỗi chính**

Ba cách chia cho kết quả chênh nhau rất ít trong bảng kết quả.

3 **Xếp hạng lại là bước cải thiện nhiều nhất**

Với mxbai, chỉ 13 đến 19 truy vấn bị xuống hạng, và trung vị chỉ xuống 1 hạng. Chỉ 0 đến 2 truy vấn bị đẩy ra khỏi top 5.

4 **Bộ đánh giá vẫn có nhiều**

18.5% truy vấn bị đánh giá là mơ hồ và 8.3% số cặp chấm lại không khớp. Mức nhiễu này lớn hơn một số chênh lệch giữa các cấu hình.

Bốn hạn chế của nghiên cứu

1 Hybrid còn chậm

Mỗi truy vấn mất khoảng 725 ms, trong đó 93% là bước xếp hạng lại. Nếu cần nhanh hơn, ms-marco-MiniLM-L6-v2 nhanh hơn khoảng 4 lần nhưng MRR chỉ đạt 0.799.

2 Độ trễ của Hybrid mới đo một lần

Lần chạy chính cho trung vị 725 ms, còn một lần chạy khác cho 921 ms. Máy đo có dao động giữa các lần chạy.

3 Truy vấn có thể thiên lệch

Truy vấn do LLM viết nên có thể dễ hơn truy vấn thật. Nhấn chưa được người chấm kiểm tra lại.

4 Kết quả có thể hơi lạc quan

Cùng một bộ 298 truy vấn vừa dùng để chọn mô hình và tham số, vừa dùng để báo cáo kết quả cuối.

KẾT LUẬN

Nhóm đề xuất dùng Hybrid với mxbai-rerank-base và cách chia semantic

0.966

RECALL@5

0.895

MRR

0.916

NDCG@10

Hệ thống hai tầng cho kết quả tốt hơn rõ rệt so với Sparse, Dense và Fusion.

Chọn mô hình xếp hạng lại và xử lý lệch từ vựng quan trọng hơn chọn cách chia đoạn.

Hướng phát triển cho E1

Mở rộng truy vấn hoặc dùng SPLADE để xử lý lệch từ vựng.

Hướng phát triển cho E2

Thêm bộ lọc theo nguyên liệu và con số cụ thể.

Hướng phát triển cho E4

Kết hợp điểm xếp hạng lại với điểm RRF.

Cảm ơn cô và các bạn đã lắng nghe

Nhóm rất mong nhận được câu hỏi và góp ý từ cô và các bạn.